

UNIVERZITET U NOVOM SADU
FAKULTET TEHNIČKIH NAUKA
KATEDRA ZA AUTOMATIKU I UPRAVLJANJE SISTEMIMA

Identifikacija sistema

Parametarska identifikacija

(deo A)

Modeliranje i simulacija sistema

O identifikaciji ...

- Nauka formira modele na osnovu posmatranja objekta (sistema) i istraživanja njegovih osobina
 - modeli su manje ili više formalnog karaktera sa ciljem da odražavaju rezultate posmatranja
- Identifikacija sistema se bavi formiranjem modela na osnovu podataka iz posmatranog sistema
 - radi se o eksperimentalnom postupku modeliranja objekta, koji se zasniva na merenju ulaza i izlaza objekta u konačnom broju trenutaka i procesiranju rezultata merenja
 - tehnike identifikacije sistema se bave organizacijom eksperimenta merenja i algoritmima obrade mernih podataka koji daju dovoljno tačne procene modela

Primena identifikacije

- Formiranje matematičkog modela sistema
 - statičkog
 - dinamičkog
- Ona je sastavni deo savremenih tehnika automatskog upravljanja
 - adaptivno upravljanje
 - inteligentno upravljanje

Modeli i identifikacija

- **White-box model** – isključivo teorijski izgrađen
- **Black-box model** – nastao isključivo na osnovu podataka iz merenja
- **Gray-box model** – kombinovano: teorija odredi oblik (klasu) modela, a preko merenja se izračunaju nepoznati delovi modela (tipično nepoznati parametri)
- **Parametarska identifikacija** - ukoliko se je model poznat sa tačnošću do nepoznatih parametara

Sprovođenje identifikacije

- **Off-line identifikacija** - formiranje modela se vrši van normalnog rada objekta
- **On-line identifikacija** – određivanje modela se vrši tokom normalnog rada objekta – neposredno nakon merenja
 - Proces je automatizovan – bez uticaja čoveka
- **Identifikaciji u realnom vremenu** - je on-line identifikacija gde se procesiranje merenih podataka (i ažuriranje modela) vrši posle svake periode odabiranja


Definicija identifikacije

- *L. Zadeh*: “Identifikacija je određivanje na osnovu ulaznih i izlaznih signala procesa, modela iz određene klase modela, koji je ekvivalentan procesu na kome su izvršena određena merenja”
- U postupku identifikacija treba:
 - usvojiti strukturu modela
 - definisati kriterijum ekvivalencije
(kriterijum za ocenu valjanosti modela)
 - izvršiti merenja (eksperimentalno dobijeni podaci)
- Definicija je opšta i obuhvata i problem određivanja strukture modela.

Identifikacija je iterativan postupak


1. Napravi se eksperiment i prikupe ulazno/izlazni podaci procesa koji se identifikuje
2. Ispitaju se dobijeni podaci: eliminišu se grube greške i trendovi; treba izabrati upotrebljiv deo podataka i po potrebi ga filtrirati
3. Izabere se ili definiše klasa modela (struktura modela)
4. Odredi se (izračuna) konkretan model iz izabrane klase modela na osnovu ulazno/izlaznih podataka i usvojenog kriterijuma optimalnosti
5. Ispitaju se osobine usvojenog modela
6. Ukoliko model ne zadovoljava treba se vratiti:
 - na korak 4 i promeniti algoritam identifikacije
 - na korak 3 i promeniti strukturu modela
 - na korak 1 ili 2 i obezbediti nove ulazno/izlazne podatke

Postupak identifikacije



Primer – Pojačavač nepoznatog pojačanja

- Klasa modela: $y(t) = q \cdot u(t)$
Na osnovu ulaza i izlaza pojačavača odrediti nepoznato pojačanje q .




- Greška merenja je: $\Delta y(t) = y_v(t) - y(t)$ jednaka mernom šumu $v(t)$.

Da bi što bolje potisnuli šum, treba $u(t)$ načiniti što većim.
Nažalost, ovo nije fizički ostvarivo.

- Tačnu vrednost parametra q nikada nećemo znati, ali možemo napraviti (izračunati) njegovu procenu $\hat{q}$.

Kroz izmerene tačke se može provući više pravih. 

Najbolje je da prava prođe “što je moguće bliže svim podacima”.



...

Ako se merenja y_{nk} vršimo u diskretnim trenucima $t = k \cdot \Delta t$, $k = 1, 2, \dots, K$ i znamo $u_k = u(k \Delta t)$, parametar q se **ne može** odrediti iz $q = (y_{vk} - v_k)/u_k$ jer je v_k nepoznato.

Procena vrednosti nepoznatog parametra

Pogodano je iskazati ukupnu grešku kao sumu razlika izmerenih izlaza y_{vk} i izlaza modela y_k :

$$\mathcal{J} = \frac{1}{2} \sum_{k=1}^K (y_{vk} - y_k)^2 = \frac{1}{2} \sum_{k=1}^K (y_{vk} - q \cdot u_k)^2$$

Ako se procena parametra označi sa $\hat{q}$ onda se ona može odrediti iz uslova

$$\min_{\hat{q}} \mathcal{J} = \min_{\hat{q}} \frac{1}{2} \sum_{k=1}^K (y_{vk} - \hat{q} u_k)^2 = \min_{\hat{q}} \frac{1}{2} \sum_{k=1}^K e_k^2$$

Primenimo metod najmanjih kvadrata.

Potreban uslova za minimum od $\mathcal{J}$ (po q)

$$\nabla \mathcal{J} = \frac{\partial \mathcal{J}}{\partial q} = - \sum_{k=1}^K e_k u_k = - \sum_{k=1}^K (y_{vk} - q u_k) u_k = 0$$

tj.
$$\left(\sum_{k=1}^K u_k^2 \right) \cdot \hat{q} = \sum_{k=1}^K u_k y_{vk}$$

Ako definišemo vektor ulaza

$$\mathbf{S} = [u_1 \quad u_2 \quad \dots \quad u_K]^T$$

i vektor merenja izlaza

$$\mathbf{Y} = [y_{v1} \quad y_{v2} \quad \dots \quad y_{vK}]^T$$

jednačina sa $\hat{q}$ postaje:

$$\mathbf{S}^T \mathbf{S} \cdot \hat{q} = \mathbf{S}^T \mathbf{Y}$$

odakle se dobija procena parametra

$$\hat{q} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{Y}$$

Primetiti da se merenja mogu grupisati kao $\mathbf{S} \cdot \hat{q} = \mathbf{Y}$ pa se q dobija pseudoinverzijom matrice $\mathbf{S}$



$$\hat{q} = \mathbf{S}^* \mathbf{Y} = ((\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T) \mathbf{Y}$$

Primer

Određivanje otpornosti otpornika na osnovu merenja jačine struje kroz njega i pada napona na njegovim krajevima.

```
julia> Umer = [ 1, 2, 3, 4, 5, 6, 7, 8, 9,10]; # [V]
julia> Imer = [6.5,24,19,55,40,51,69,67,74,75]; # [mA]
julia> Imer = Imer / 1000; # [A]
julia> R = Imer \ Umer #  $R = \text{Imer}' * \text{Umer} / (\text{Imer}' * \text{Imer})$ 
114.59838038958196
```

```
julia> # Izbacivanje 4. tog merenja
julia> sel = 1:length(Umer) .!= 4;
julia> Umer = Umer[sel];
julia> Imer = Imer[sel];
julia> R = Imer \ Umer
119.55936352509181
```



Model sa više parametara

Posmatramo sistem sa više parametara gde je izlaz linearan po nepoznatim parametrima

$$y_v(t) = \varphi_1(t)q_1 + \varphi_2(t)q_2 + \dots + \varphi_p(t)q_p + v(t)$$

Ili

$$y_v(t) = \mathbf{\Phi}(t) \cdot \mathbf{q} + v(t)$$

- y_v – izmerena vrednost izlaza iz sistema;
- $\mathbf{\Phi}$ – vektor funkcija $\mathbf{\Phi} = [\varphi_1 \ \varphi_2 \ \dots \ \varphi_p]$,
gde svaka funkcija $\varphi_i = \varphi_i(t, u_1, \dots, u_m)$ zavisi od ulaza u sistem $u_1, \dots, u_m$;
- $\mathbf{q}$ – vektor nepoznatih konstantnih parametara, $\mathbf{q} = [q_1 \ q_2 \ \dots \ q_p]^T$;
- v – šum

Primer ovakvog modela sa 3 ulaza i 9 nepoznatih parametara:

$$y = q_1 u_1 + q_2 u_2 + q_3 u_3 + q_4 u_1 u_2 + q_5 u_1 u_3 + q_6 u_2 u_3 + q_7 u_1^2 + q_8 u_2^2 + q_9 u_3^2$$

$$\varphi_j(u) = u_j, \quad j = 1, 2, 3$$

$$\varphi_j(u) = u_j^2, \quad j = 7, 8, 9$$

$$\varphi_4(u) = u_1 u_2, \quad \varphi_5(u) = u_1 u_3, \quad \varphi_6(u) = u_2 u_3$$

Primetiti da je **izlaz linearan po parametrima**, dok su funkcije ulaza φ_j nelinearne.

Procena više parametara

- Imamo p nepoznatih parametara i isto toliko funkcija koje zavise od m ulaza
- Ponavljamo eksperiment K puta ($k = 1, 2, \dots, K$)
 - Zadamo ulazne vrednosti $u_{1k}, u_{2k}, \dots, u_{mk}$ (svaki put promenimo ulaze)
 - Izmerimo izlaz y_{vk}
 - izračunamo vrednosti funkcija $\varphi_{ki}, i = 1, 2, \dots, p$

Podaci se organizuju u matrice/vektore

$$\mathbf{S} = \begin{bmatrix} \varphi_{11} & \varphi_{12} & \dots & \varphi_{1p} \\ \varphi_{21} & \varphi_{22} & \dots & \varphi_{2p} \\ \dots & \dots & \dots & \dots \\ \varphi_{K1} & \varphi_{K2} & \dots & \varphi_{Kp} \end{bmatrix} = \begin{bmatrix} \boldsymbol{\Phi}_1 \\ \boldsymbol{\Phi}_2 \\ \dots \\ \boldsymbol{\Phi}_K \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} y_{v1} \\ y_{v2} \\ \dots \\ y_{vK} \end{bmatrix}$$

- Mera razlike realnog sistema i modela definiše kriterijum optimalnosti $\mathcal{J}$

$$\mathcal{J} = \frac{1}{2} \sum_{k=1}^K (y_{nk} - \boldsymbol{\Phi}_k \mathbf{q})^2 = \frac{1}{2} \sum_{k=1}^K e_k^2 = \frac{1}{2} \mathbf{e}^T \mathbf{e} = \frac{1}{2} (\mathbf{Y} - \mathbf{S} \mathbf{q})^T (\mathbf{Y} - \mathbf{S} \mathbf{q})$$

... Procena više parametara

traži se minimum od $\mathcal{J}$ po $\mathbf{q}$

$$\mathcal{J} = \frac{1}{2} (\mathbf{Y} - \mathbf{S}\mathbf{q})^T (\mathbf{Y} - \mathbf{S}\mathbf{q})$$

Potreban uslov minimuma je

$$\nabla \mathcal{J} = \frac{\partial \mathcal{J}}{\partial \mathbf{q}} \big|_{\mathbf{q}=\hat{\mathbf{q}}} = 0$$

odakle je (izvođenje je u knjizi)

$$\hat{\mathbf{q}} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{Y}$$

Obratiti pažnju da je sada $\hat{\mathbf{q}}$ vector sa p vrednosti, koliko ima nepoznatih parametara.

Ako merimo sa greškom $v(k) \neq 0$, da li i pod kojim uslovima se može odrediti tačna vrednost nepoznatog parametra $\mathbf{q}$?

Nepomerena procena parametara

Izlaz modela je $\mathbf{Y} = \mathbf{S}\mathbf{q} + \mathbf{N}$ te je $\hat{\mathbf{q}} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{Y} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T (\mathbf{S}\mathbf{q} + \mathbf{N}) = \mathbf{q} + (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{N}$ i procena zavisi od šuma.

Pretpostavimo da iste parametre određujemo više puta.

- Potrebni K merenja za jednu procenu parametara ponavljamo R puta – R nezavisnih procena
- Srednja vrednost procena je (matematičko očekivanje $E\{.\}$) $E\{\hat{\mathbf{q}}\} = \mathbf{q} + (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T E\{\mathbf{N}\}$


$$E\{\mathbf{N}\} = \begin{bmatrix} E\{v_1\} \\ E\{v_2\} \\ \dots \\ E\{v_K\} \end{bmatrix}$$

- Ako je šum beo tada je mu je srednja vrednost 0.

Srednja vrednost šuma kod prvog merenja u celoj seriji merenja

$$E\{v_i\} = \frac{1}{R} \sum_{r=1}^R v_{i,r} = \mu$$

$$E\{\mathbf{N}\} = \begin{bmatrix} \mu \\ \mu \\ \dots \\ \mu \end{bmatrix}_{K \times 1} = \begin{bmatrix} 0 \\ 0 \\ \dots \\ 0 \end{bmatrix}_{K \times 1}$$



$$\underline{E\{\hat{\mathbf{q}}\} = \mathbf{q}}$$

Nepomerena procena parametara (2)

Procena parametara je **nepomerena** kada je očekivana vrednost jednaka $\mathbf{q}$, tj. $E\{\hat{\mathbf{q}}\} = \mathbf{q}$

- U praksi, umesto da se procena parametara ponavlja R puta dovoljno je napraviti jednu procenu, ali sa velikim brojem uzoraka (K je veliko).
- dobija se nepomerena procena parametara modela (linearnog po parametrima) ako se na izlaz dodaje beli šum.
- Međutim, kako je K konačno veliko, srednja vrednost signala šuma će biti različita od nule i to će nakon svake procene dati drugačije vrednosti parametara, te se postavlja pitanje koliko je rasipanje tih vrednosti?
- Rasipanje se procenjuje preko **kovarijacione matrice**

$$\mathbf{C} = E\{(\hat{\mathbf{q}} - \mathbf{q})(\hat{\mathbf{q}} - \mathbf{q})^T\}$$

Kovarijaciona matrica

- $\hat{\mathbf{q}} = \mathbf{q} + (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{N}$
- $\mathbf{C} = E\{(\hat{\mathbf{q}} - \mathbf{q})(\hat{\mathbf{q}} - \mathbf{q})^T\} = E\{(\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{N} \mathbf{N}^T \mathbf{S} (\mathbf{S}^T \mathbf{S})^{-1}\} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T E\{\mathbf{N} \mathbf{N}^T\} \mathbf{S} (\mathbf{S}^T \mathbf{S})^{-1}$
- $\mathbf{N} \mathbf{N}^T$ se odnosi na jednu procenu parametara

$$\mathbf{N} \mathbf{N}^T = \begin{bmatrix} v_1^2 & v_1 v_2 & \dots & v_1 v_K \\ v_2 v_1 & v_2^2 & \dots & v_2 v_K \\ \dots & \dots & \dots & \dots \\ v_K v_1 & v_K v_2 & \dots & v_K^2 \end{bmatrix}$$

- Kada se ponovi R procena možemo odrediti srednju vrednosti

$$E\{\mathbf{N} \mathbf{N}^T\} = \begin{bmatrix} E\{v_1^2\} & E\{v_1 v_2\} & \dots & E\{v_1 v_K\} \\ E\{v_2 v_1\} & E\{v_2^2\} & \dots & E\{v_2 v_K\} \\ \dots & \dots & \dots & \dots \\ E\{v_K v_1\} & E\{v_K v_2\} & \dots & E\{v_K^2\} \end{bmatrix} = \begin{bmatrix} \sigma_v^2 & 0 & \dots & 0 \\ 0 & \sigma_v^2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_v^2 \end{bmatrix}$$

- Ako je šum beo tada važi

$$E\{v_k^2\} = \frac{1}{R} \sum_{i=1}^R v_{i,k}^2 = \sigma_v^2$$

$$E\{v_k v_m\} = \frac{1}{R} \sum_{i=1}^R v_{k,i} v_{m,i} = 0, \quad k \neq m, \quad R \rightarrow \infty$$

Ako je šum beo

Efikasna procena parametara

- Rasipanje procene parametara

$$\mathbf{C} = E\{(\hat{\mathbf{q}} - \mathbf{q})(\hat{\mathbf{q}} - \mathbf{q})^T\} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T E\{\mathbf{N} \mathbf{N}^T\} \mathbf{S} (\mathbf{S}^T \mathbf{S})^{-1} = \underbrace{(\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T \mathbf{S}}_{\mathbf{I}} \sigma_v^2 (\mathbf{S}^T \mathbf{S})^{-1}$$

$$= \begin{bmatrix} \sigma_v^2 & 0 & \dots & 0 \\ 0 & \sigma_v^2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_v^2 \end{bmatrix} (\mathbf{S}^T \mathbf{S})^{-1} = \sigma_v^2 (\mathbf{S}^T \mathbf{S})^{-1}$$

(za beli šum)

„izašlo“ ispred jer je
 $E\{\mathbf{N} \mathbf{N}^T\}$ dijagonalna
matrica $= \sigma_v^2 \mathbf{I}$

- Procena parametara je **efikasna** kada za veliki broj merenja K važi da je

$$\lim_{K \rightarrow \infty} \sigma_{\hat{\mathbf{q}}}^2 \rightarrow 0$$

Tačne vrednosti parametara

- Postupak parametarske identifikacije dovodi to tačnih parametara ako je procena nepomerena i efikasna.
- Procena parametara modela $y_v(t) = \boldsymbol{\Phi}(t) \cdot \boldsymbol{q} + v(t)$ će biti tačna ako šum $v(t)$ ima osobine belog šuma i imamo veliki broj merenja.

Procena rasipanja

- Iskustveno se može reći da je tačna vrednost parametara u okolini procenjene vrednosti

$$\mathbf{q} = \hat{\mathbf{q}} \pm 2\sigma_{\hat{\mathbf{q}}}$$

gde je $\sigma_v^2 (\mathbf{S}^T \mathbf{S})^{-1} = \sigma_{\hat{\mathbf{q}}}^2$, tj. za procenu disperzije parametara treba nam procena disperzije šuma.

- Formira se vektor reziduala $\boldsymbol{\varepsilon}$ na osnovu $\varepsilon_k = y_{vk} - u_k \hat{q}$, $k = 1, 2, \dots, K$
$$\boldsymbol{\varepsilon} = \mathbf{Y} - \mathbf{S}\hat{\mathbf{q}}$$
- Rezidual ne može biti jednak šumu v_k koji je nemerljiv, ali se za dovoljno veliko K može upotrebiti za procenu greške merenja

$$\sigma_v^2 \approx \frac{1}{K} \sum_{k=1}^K \varepsilon_k^2 = \frac{\boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon}}{K}$$

$$\sigma_{\hat{\mathbf{q}}}^2 = \sigma_v^2 (\mathbf{S}^T \mathbf{S})^{-1}$$

$$\mathbf{q} = \hat{\mathbf{q}} \pm 2\sigma_{\hat{\mathbf{q}}}$$

Osobina identifiabilnosti

Neka je izlaz modela linearan po parametrima

$$y_v = \sum_{i=1}^r q_i \varphi_i\{u(t)\} + v(t)$$

Radi jednostavnosti, posmatramo primer sa 2 parametra:

$$y_v = q_1 \varphi_1(u) + q_2 \varphi_2(u) + v(t)$$

pa je:

$$\hat{\mathbf{q}} = \begin{bmatrix} \hat{q}_1 \\ \hat{q}_2 \end{bmatrix} = (\mathbf{S}^T \mathbf{S})^{-1} (\mathbf{S}^T \mathbf{Y})$$

za:

$$\mathbf{S} = \begin{bmatrix} \varphi_1(u_1) & \varphi_2(u_1) \\ \varphi_1(u_2) & \varphi_2(u_2) \\ \vdots & \vdots \\ \varphi_1(u_K) & \varphi_2(u_K) \end{bmatrix}_{K \times 2}$$

$$\mathbf{S}^T \mathbf{S} = \begin{bmatrix} \sum_{k=1}^K \varphi_1^2(u_k) & \sum_{k=1}^K \varphi_1(u_k) \varphi_2(u_k) \\ \sum_{k=1}^K \varphi_1(u_k) \varphi_2(u_k) & \sum_{k=1}^K \varphi_2^2(u_k) \end{bmatrix}$$

Izraz za $\hat{\mathbf{q}}$ se ne može rešiti ako je $\det(\mathbf{S}^T \mathbf{S}) = 0$, a to će se desiti kada su funkcije φ_1 i φ_2 linearno zavisne.

Tj., za $\varphi_2(u) = c \varphi_1(u)$ dobija je

$$\mathbf{S}^T \mathbf{S} = \begin{bmatrix} 1 & c \\ c & c^2 \end{bmatrix} \sum_{k=1}^K \varphi_1^2(u_k)$$

Tada kažemo da model nije identifiabilan.

Identifiabilnost i funkcije osetljivosti

Sada posmatramo opštiji slučaj, gde izlaz nije linearan po parametrima.

Tada je proces određivanja parametara iterativan, gde se u svakoj iteraciji procena parametara popravlja za $\Delta \mathbf{q}$

$$y(t, \mathbf{q} + \Delta \mathbf{q}) \approx y(t, \mathbf{q}) + \frac{\partial y}{\partial q_1} \Delta q_1 + \frac{\partial y}{\partial q_2} \Delta q_2 = y(t, \mathbf{q}) + U_1(t, \mathbf{q}) \Delta q_1 + U_2(t, \mathbf{q}) \Delta q_2$$

Definišu se funkcije osetljivosti:

$$U_i(t, \mathbf{q}) = \frac{\partial y(t, \mathbf{q})}{\partial q_i}, \quad i = 1, 2, \dots, r$$

- Ako su funkcije osetljivosti linearno zavisne onda je model neidentifiabilan
- Ovaj uslov važi i kada model nije linearan po q , pa se zato identifiabilnost posmatra preko funkcija osetljivosti.

– u prethodnom primeru je:

$$U_1(t, \mathbf{q}) = \varphi_1(u)$$

$$U_2(t, \mathbf{q}) = \varphi_2(u)$$



Ovde su funkcije osetljivosti nezavisne od q
pa je model linearan po q

Beli šum

- Statističke osobine signala $x_i, i = 1, 2, \dots, N$:

- Srednja vrednost

$$\mu = \frac{1}{N} \sum_{i=1}^N x_i$$

- Standardna devijacija

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Disperzija je σ^2


- Autokorelacija za pomeraj k

$$R(k) = \frac{1}{(N-k)\sigma^2} \sum_{i=1}^{N-k} (x_i - \mu)(x_{i+k} - \mu)$$

- Osobine signala belog šuma:

- Srednja vrednost 0
- Standardna devijacija 1
- Autokorelacija je 0 za sve pomeraje signala $k = 1, 2, 3, \dots$

- Može se predstaviti generatorom slučajnih brojeva po normalnoj raspodeli.



Generator pseudoslučajnih brojeva

- Generator pseudoslučajnih brojeva generiše pseudoslučajne brojeve (PSB) u sekvencama (nizovima)
 - Generator implementira algoritam - tako da je proces deterministički
 - Generator ima stanje, tako da naredni PSB zavisi od prethodno generisanog – nema slučajnosti!
 - Generisani brojevi se ponavljaju u velikim ciklusima
- Generisani brojevi aproksimiraju osobine slučajnih brojeva – upotrebljivi su.
- Koristimo ga da modelujemo događaje kod slučajnih procesa
- Ovde modelujemo beli šum

Upotreba generatora pseudoslučajnih brojeva u Juliji

- Osnovne funkcije Random modula generišu brojeve po uniformnoj, normalnoj ili eksponencijalnoj raspodeli.
 - `rand(n)` sekvenca `n` brojeva po uniformnoj raspodeli
 - `randn(n)` sekvenca `n` brojeva po normalnoj raspodeli
- Generator brojeva se može zadati
 - Julija paket `Distributions` proširuje mogućnosti Random modula

```
julia> using Random

julia> x = rand(2)           # generisanje 2 slučajna broja po uniformnoj raspodeli
2-element Array{Float64,1}:
 0.5620030102420666
 0.5858419960539349

julia> y = randn(3)          # generisanje 3 slučajna broja po normalnoj raspodeli
3-element Array{Float64,1}:
 0.8673472019512456
-0.9017438158568171
-0.4944787535042339
```

Ponovljivost brojeva u sekvenci

- Zbog ponovljivosti testiranja, pogodno je postaviti „seme“ generatora brojeva
 - `Random.seed!(seme)`

```
julia> Random.seed!(1234); # prvo seme A
julia> y = rand(2);        # Prva sekvenca: dva broja
julia> z = rand(2);        # i još dva broja, ukupno 4
julia> Random.seed!(34);   # drugo seme B
julia> v = rand(4);        # Druga sekvenca od 4 broja
julia> v == [y; z]         # provera, da li su sekvence jednake? NISU
false

julia> Random.seed!(1234); # opet prvo seme A
julia> w = rand(4);        # Treća sekvenca
julia> w == [y; z]         # provera, da li su sekvence jednake? JESU jer su nastale iz istog semena.
true
```

Uniformna raspodela

Uniformna raspodela ima jednaku verovatnoću $P(X)$ da slučajna promenljiva X primi bilo koju vrednost iz intervala $[a, b]$

Stoga je funkcija raspodele (gustine) verovatnoće (PDF - *Probability Density Function*) konstantna.

$$f(x) = P(X \in [a, b]) = \frac{1}{b - a}$$


Funkcija kumulativne raspodele verovatnoće (CDF - *Cumulative Distribution Function*) je prava

$$F(x) = P(X < x) = \int_{-\infty}^x f(x)dx$$

```
julia> using Distributions
julia> dist = Uniform(0,1)      # interval [0,1)
Uniform{Float64}(a=0.0, b=1.0)

julia> p = pdf.(dist, [0, 0.2, 0.5, 1])
4-element Array{Float64,1}:
 1.0
 1.0
 1.0
 1.0

julia> c = cdf.(dist, [0, 0.2, 0.5, 1])
4-element Array{Float64,1}:
 0.0
 0.2
 0.5
 1.0
```



Računato za neke vrednosti slučajne promenljive

Uniformna raspodela

```
julia> using Statistics
julia> n = 1000000;
julia> Random.seed!(1234);
julia> X = rand(n);      # prva sekvenca
julia> xsr = mean(X)     # srednja vrednost
0.5000094359175243


julia> xsd = std(X)      # standardna devijacija
0.28871485532081553

julia> X = rand(n);      # druga sekvenca
julia> xsr = mean(X)
0.49954367089725193


julia> xsd = std(X)
0.2887237693896342

julia> dijagrami(X)
```

Signal (prvih 100 vrednosti)



Broj pojava vrednosti u intervalima



Normalna (Gausova) raspodela


Normalna raspodela ima funkciju raspodele
(gustine) verovatnoće
(PDF - *Probability Density Function*)

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

μ je srednja vrednost, σ je standardna devijacija.

Funkcija kumulativne raspodele verovatnoće
(CDF - *Cumulative Distribution Function*) nije
elementarna funkcija i računa se numerički

```
# Teorijske krive pdf, cdf
x = -5:0.05:5;
dist = Normal(0,1);
f = pdf.(dist, x);
F = cdf.(dist, x);
g1 = plot(x, f, title="Raspodela verovatnoca", lab="")
g2 = plot(x, F, title="Kumulativna raspodela verovatnoca", lab="")
plot(g1, g2, layout=(2,1))
```




Normalna raspodela


```
# Generisanje 2 slučajna broja po normalnoj raspodeli  
# sa srednjom vrednosti 0, standardnom devijacijom 1  
Random.seed!(1234);  
x = rand(Normal(0.,1.), 2)  
Random.seed!(1234);  
x = randn(2)
```

```
julia> using Statistics  
julia> n = 1000000;  
julia> X = randn(n);  
julia> xsr = mean(X)    # srednja vrednost  
-0.0002229283544421054  
julia> xsd = std(X)     # standardna devijacija  
1.0010411639514238  
julia> dijagrami(X)
```

Signal (prvih 100 vrednosti)




Broj pojava vrednosti u intervalima



Kako se generišu slučajne vrednosti po željenoj raspodeli?

- Generiše se slučajna vrednost y po uniformnoj raspodeli u intervalu $[0,1)$
$$y = F(x) \in [0,1]$$
- Primenom inverzne funkcije kumulativne raspodele verovatnoće na prethodno generisanu vrednost $F^{-1}(y)$ se dobija tražena slučajna promenljiva x .


```
# Generisanje SP po normalnoj raspodeli na osnovu uniformne raspodele.  
# preko primene inverzne CDF == quantile  
Xu = rand(n);  
dist = Normal(0,1);  
X = quantile.(dist, Xu);  
xsr = mean(X)    # srednja vrednost  
xsd = std(X)     # standardna devijacija  
  
dijagrami(X)
```



Normalna raspodela kada su zadati μ , σ

- Način 1: Generiše se slučajna vrednost x po normalnoj raspodeli sa $\mu_x = 0$ i $\sigma_x = 1$, i izračuna $\sigma x + \mu$
- Način 2: U paketu Distributions se postave željeni paramteri normalne raspodele

```
 $\mu$  = 7.5;  
 $\sigma$  = 2.5;  
  
n = 1000000;      # n je veličina sekvence  
# način 1  
x = randn(n);  
y =  $\sigma$  * x .+  $\mu$ ;  
# ili ...  
# način 2  
dist = Normal(7.5, 2.5);  
y = rand(dist, n);  
  
ysr = mean(y)  
ysd = std(y)  
# koliko vrednosti se nalazi u intervalu [ $\mu - \sigma, \mu + \sigma$ ]  
sum( $\mu - \sigma$  .<= y .<=  $\mu + \sigma$ ) * 100.0 / n  
sum( $\mu - 2\sigma$  .<= y .<=  $\mu + 2\sigma$ ) * 100.0 / n  
sum( $\mu - 3\sigma$  .<= y .<=  $\mu + 3\sigma$ ) * 100.0 / n
```



```
julia> ysr = mean(y)  
7.501189642245626  
  
julia> ysd = std(y)  
2.5006676394955747  
  
julia> sum( $\mu - \sigma$  .<= y .<=  $\mu + \sigma$ ) * 100.0 / n  
68.2194  
  
julia> sum( $\mu - 2\sigma$  .<= y .<=  $\mu + 2\sigma$ ) * 100.0 / n  
95.4569  
  
julia> sum( $\mu - 3\sigma$  .<= y .<=  $\mu + 3\sigma$ ) * 100.0 / n  
99.7287
```



Analiza signala belog šuma

- Signal belog šuma se može modelovati generatorom slučajnih vrednosti po normalnoj raspodeli ($\mu = 0, \sigma = 1$)
- Takođe, autokorelacija je 0 za sve pomeraje signala $k = 1, 2, 3, \dots$

```
function autocorr(X,k)
    Y = X[:] .- mean(X) # X[:] je uvek vector kolona
    n = length(Y)
    s = std(Y)
    R = 1/(n - k)/s^2 * Y[1:n-k]' * Y[k+1:n]
    return R
end

K = 1000000 # broj merenja
Random.seed!(1234);
ni = randn(K)
r = []
for k = 0 : 20 # pomeraj
    a = autocorr(ni,k)
    push!(r, a)
end
g1 = plot(0:20, r, title="Autokorelacija",
    marker=2, lab="", xlabel="k")
```

$$R(k) = \frac{1}{(N - k)\sigma^2} \sum_{i=1}^{N-k} (x_i - \mu)(x_{i+k} - \mu)$$



Obojen šum

- Beli šum se „boji“ propuštanjem kroz filter.

- Primer 1: Filter je polinom po z^{-1}

Npr. $Q(z) = 1 - 1.6551z^{-1} + 0.7408z^{-2}$

$$v_0(k) = Q(z)v(k) = (1 - 1.6551z^{-1} + 0.7408z^{-2})v(k)$$

Obojeni šum

Beli šum

Sabira se nekoliko uzastopnih vrednosti množenih koeficijentima polinoma Q

$$v_0(k) = v(k) + q_1v(k-1) + q_2v(k-2)$$

- Primer 2: Filter je funkcija diskretnog prenosa

Npr. $W(z) = \frac{P(z)}{Q(z)} = \frac{0.0045z^{-1} + 0.0041z^{-2}}{1 - 1.6551z^{-1} + 0.7408z^{-2}}$

$$v_0(k) = \frac{P(z)}{Q(z)}v(k) = \frac{0.0045z^{-1} + 0.0041z^{-2}}{1 - 1.6551z^{-1} + 0.7408z^{-2}}v(k)$$


$$v_0(k) = -q_1v_0(k-1) - q_1v_1(k-2) + p_1v(k-1) + p_2v(k-2)$$

Obojen šum (2)


```
using ControlSystems
```

```
P = [1.0, 0, 0]  
Q = [1, -1.6551, 0.7408]  
W = tf(Q, P, 1.0)  
nio,_,_ = lsim(W, ni, 0:length(ni)-1)  
niosr, niosd, nior = analizaSuma(nio)  
diagrami(nio, nior)
```


Signal



Autokorelacija




Broj pojava vrednosti u intervalima




```
P = [0, 0.0045, 0.0041]  
Q = [1, -1.6551, 0.7408]  
W = tf(P, Q, 1.0)  
nio,_,_ = lsim(W, ni, 0:length(ni)-1)  
niosr, niosd, nior = analizaSuma(nio)  
diagrami(nio, nior)
```

Signal



Autokorelacija



Broj pojava vrednosti u intervalima

