

#	Pitanje	Odgovor
1	Napisati kod za rešavanje sistema jednačina: $x_1 + 2x_2 = -2.5$ $-x_1 + 3x_2 = 0.5$	$A = \begin{bmatrix} 1 & 2 \\ -1 & 3 \end{bmatrix};$ $b = \begin{bmatrix} -2.5 \\ 0.5 \end{bmatrix};$ $x = A \setminus b$
2	Primenom metode najmanjih kvadrata izračunati x za sistem jednačina: $x = -2$ $-2x = 5$	$A = \begin{bmatrix} 1 \\ -2 \end{bmatrix}, b = \begin{bmatrix} -2 \\ 5 \end{bmatrix}$ $x = (A^T A)^{-1} A^T b = (5)^{-1}(-12) = -\frac{12}{5}$
3	Napisati funkciju cilja kod primene metode najmanjih kvadrata na problem: $a_{11}x_1 + a_{12}x_2 = b_1$ $a_{21}x_1 + a_{22}x_2 = b_2$	$a_{11}x_1 + a_{12}x_2 - b_1 = e_1$ $a_{21}x_1 + a_{22}x_2 - b_2 = e_2$ $J = \frac{1}{2}(e_1^2 + e_2^2)$
4	Opisan je sistem algebarskih jednačina matričnim izazom $\begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 2 & 3 \end{bmatrix} = \begin{bmatrix} -2.5 & 0.5 \end{bmatrix}.$ Napisati kod koji nalazi rešenja.	$A = \begin{bmatrix} 1 & -1 \\ 2 & 3 \end{bmatrix};$ $b = \begin{bmatrix} -2.5 \\ 0.5 \end{bmatrix};$ $x = b / A$
5	Kako se matematički definiše pseudoinverzija matrice A ?	$A^* = (A^T A)^{-1} A^T$
6	Navesti kriterijume zaustavljanja Njutnovog algoritma. Objasniti šta je šta.	$ \Delta x_k \leq \varepsilon_x$ promena zavisno promenljive je dovoljno mala, manja od zadatog ε_x $f(x_k)^2 \leq \varepsilon_f$ vrednost funkcije je bliska nuli, f^2 manja od zadatog ε_f $k > k_{max}$ broj iteracija je veći od propisanog k_{max}
7	Napisati problem i izvesti Njutnov algoritam?	Problem: $f(x) = 0$ $x_{k+1} = x_k + \Delta x_k, k = 0, 1, \dots$ $f(x_k + \Delta x_k) \approx f(x_k) + f'(x_k)\Delta x_k = 0$ $\Delta x_k = -\frac{f(x_k)}{f'(x_k)}$
8	Napisati formulu za funkciju cilja za rešavanje sistema nelinearnih algebarskih jednačina (u matričnom obliku).	Zadat je sistem jednačina $f(x) = 0$. Suma kvadrata je: $J(x) = \frac{1}{2} f^T(x) f(x)$
9	Šta treba definisati kod primene Gaus-Njutnovog algoritma?	Treba definisati vektor funkcija oblika $f(x) = 0$ i Jakobijan $\nabla f(x)$.

10	Šta treba definisati kod primene Gaus-Njutnovog algoritma za rešavanje sistema jednačina: $x_1^2 + 2x_2 = -2.5$ $-x_1x_2 + 3x_2 = 0.5$	Funcije kao vektor $\begin{bmatrix} f_1 \\ f_2 \end{bmatrix} = \begin{bmatrix} x_1^2 + 2x_2 + 2.5 \\ -x_1x_2 + 3x_2 - 0.5 \end{bmatrix}$ i Jakobijan $\nabla \mathbf{f} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 2x_1 & 2 \\ -x_2 & 3 - x_1 \end{bmatrix}$
11	Ako postoji programska funkcija GausNjutn(fja, Jakobijan, x0) napisati kod koji rešava sledeći problem: $x^2 + \sin x = 1$, polazeći iz tačke 1.	$f(x) = x^2 + \sin(x) - 1$; $J(x) = 2x + \cos(x)$; $x = \text{GausNjutn}(f, J, 1)$
12	Izvesti formulu za primenu gradijentnog algoritma na rešavanje skupa nelinearnih jednačina $\mathbf{f}(x) = 0$.	$J(\mathbf{x}_k) = \frac{1}{2} \mathbf{f}^T(\mathbf{x}_k) \cdot \mathbf{f}(\mathbf{x}_k)$ $\Delta \mathbf{x}_k = -h \cdot \nabla J(\mathbf{x}_k), \quad h > 0$ $\nabla J(\mathbf{x}_k) = \nabla(\mathbf{f}^T(\mathbf{x}_k) \cdot \mathbf{f}(\mathbf{x}_k)) = \mathbf{J}^T(\mathbf{x}_k) \cdot \mathbf{f}(\mathbf{x}_k)$, gde je $\mathbf{J} = \nabla \mathbf{f}$ $\Delta \mathbf{x}_k = -h \cdot \mathbf{J}^T(\mathbf{x}_k) \cdot \mathbf{f}(\mathbf{x}_k)$
13	Ako je $\Delta \mathbf{x}_k = -(\mathbf{J}^T(\mathbf{x}_k)\mathbf{J}(\mathbf{x}_k))^{-1} \mathbf{J}^T(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k)$ kod Gaus-Njutnovog algoritma, napisati formulu za $\Delta \mathbf{x}_k$ kod Levenberg–Markart algoritma.	$\Delta \mathbf{x}_k = -(\mathbf{J}^T(\mathbf{x}_k)\mathbf{J}(\mathbf{x}_k) + \lambda_k \mathbf{I})^{-1} \mathbf{J}^T(\mathbf{x}_k)\mathbf{f}(\mathbf{x}_k)$ gde je pozitivna vrednost λ_k koja se menja tokom rada algoritma.
14	Koje su osobine Gradijentnog algoritma?	Brzo napredovanje u početnim iteracijama, ali sporo na kraju u okolini optimuma. Veliki broj iteracija.
15	Koje su osobine Gaus-Njutnovog algoritma?	Brzo završavanje (konvergencija u okolini optimuma), ali moguća divergencija u početnim iteracijama. Mali broj iteracija.
16	Zašto se gradijentni algoritam naziva i algoritam najstrmijeg pada?	Zato što je korekcija $\mathbf{x}$ u svakoj iteraciji $\Delta \mathbf{x}_k = -h \cdot \nabla J(\mathbf{x}_k)$, $h > 0$ srazmerna gradijentu od J (najbrži porast) ali sa suprotnim predznakom-smerom (najbrži pad).
17	Zašto gradijentni algoritam pravi mnogo iteracija?	Jer su izvodi u okolini cilja (minimuma) veoma mali pa je malo $\Delta \mathbf{x}_k$.
18	Matematički (vektorski) definisati problem koji rešavaju Runge-Kuta metode.	Rešavaju sistem običnih diferencijalnih jednačina 1. reda. $\frac{dy}{dt} = \mathbf{f}(\mathbf{y}, t), \quad \mathbf{y}(t_0) = \mathbf{y}_0$

19	Zašto numeričko rešavanje običnih diferencijalnih jednačina (ODJ) ima promenljivi korak integracije?	Zato što ne znamo unapred koliki korak treba da postavimo. Pogodnije je da algoritam za rešavanje ODJ prilagođava korak na osnovu propisane apsolutne i/ili relativne greške računanja.
20	Kako Ojlerov postupak 1. reda rešava $\frac{dy}{dt} = f(y, t)$	$y_{i+1} = y_i + f(y_i, t_i)h$ $t_{i+1} = t_i + h$ $i = 1, 2, \dots$
21	Kako računa Ojlerov postupak 2. reda? Pomoć: $\varepsilon_i = \left(\frac{dy_{i+1}^p}{dt} - \frac{dy_i}{dt} \right) \frac{h}{2}$	$y_{i+1}^p = y_i + \frac{dy_i}{dt} h$ $y_{i+1}^c = y_{i+1}^p + \varepsilon_i$
22	Objasniti kako se prilagođava korak integracije kod Ojlerovog postupka. Pomoć: $\varepsilon_i = \left(\frac{dy_{i+1}^p}{dt} - \frac{dy_i}{dt} \right) \frac{h}{2}$	Kod računanja korigovane vrednosti $y_{i+1}^c = y_{i+1}^p + \varepsilon_i$, korekcija ε_i direktno zavisi od koraka h i ukoliko je korekcija veća od unapred propisane vrednosti onda korak h treba smanjiti, i obrnuto.
23	Zašto govorimo o familiji metoda Runge-Kuta 2. reda?	Runge-Kuta metode uvode međuzavisne parametre gde postoji sloboda izbora njihovih vrednosti.
24	Kako se Runge-Kuta metod primenjuje na rešavanje obične diferencijalne jednačine 3. reda?	Tako što se ta jednačina prepiše u ekvivalentan sistem od 3 diferencijalne jednačine 1. reda.
25	Napisati kod koji rešava diferencijalne jednačine upotrebom paketa DifferentialEquations $y_1'(t) = -2y_2 + t, \quad y_1(0) = 2.$ $y_2'(t) = y_1 y_2, \quad y_2(0) = 1$	<pre>function f!(dy,y,p,t) dy[1] = -2y[2]+t; dy[2]= y[1]*y[2]; end prob = ODEProblem(f!, [2;1.], (0,15.)) r = solve(prob)</pre>
26	Nacrtati vremenski dijagram rešenja običnih diferencijalnih jednačina dobijenog primenom paketa DifferentialEquations.	<pre>#... r = solve(prob) plot(r.t, r.u)</pre>
27	Napisati kod koji upotrebom paketa DifferentialEquations nalazi $y(5)$. $y'(t) = -2y + t, \quad y(0) = -1.$	<pre>f(y,p,t) = -2y+t; prob = ODEProblem(f, -1., (0,5.)) r = solve(prob) y = r.u[end]</pre>

28	Imamo funkciju prenosa $W(s) = 2 + \frac{1}{s}$. Kako glasi funkcija prenosa kada je jedinična negativna povratna sprega zatvori oko $W(s)$?	$W(s) = \frac{2s+1}{s} = \frac{P(s)}{Q(s)}$ $W_s(s) = \frac{W}{1+W} = \frac{P(s)}{P(s)+Q(s)} = \frac{2s+1}{3s+1}$
29	Imamo funkciju prenosa $W(s) = 2 + \frac{1}{s}$, a $Q(s)$ se dobija kada je jedinična negativna povratna sprega zatvori oko $W(s)$? Napisati kod upotrebom ControlSystems paketa koji određuje $Q(s)$.	$W = \text{tf}([2, 1], [1 \ 0])$ $Q = \text{feedback}(W, 1)$ 
30	Kako model $W(z) = \frac{z+0.9}{z+2}$ opisujemo u ControlSystems paketu, kada je perioda odabiranja 0.02?	$W = \text{tf}([1, 0.9], [1, 2], 0.02)$
31	Kako model $W(z^{-1}) = \frac{z^{-1}+0.9}{z^{-1}+2}$ opisujemo u ControlSystems paketu, kada je perioda odabiranja 0.02?	$W(z) = \frac{1+0.9z}{1+2z}$ $W = \text{tf}([0.9, 1], [2, 1], 0.02)$
32	Napisati programski kod za računanje odziva funkcije prenosa $W(s) = \frac{2}{3+s}$ na jediničnu pobudu.	$W = \text{tf}(2, [1, 3])$ $y = \text{step}(W)$
33	Napisati programski kod za računanje odziva funkcije prenosa $W(s) = \frac{2}{3+5s}$ na pobudu $u(t) = t$.	$W = \text{tf}(2, [5, 3])$ $t = 0:0.01:5;$ $y = \text{lsim}(W, t, t)$
34	Napisati programski kod za računanje odziva funkcije prenosa $W(s) = \frac{2}{3+5s}$ na pobudu $u(t) = \sin(t)$.	$W = \text{tf}([2, 1], 1)$ $t = 0:0.01:5;$ $y = \text{lsim}(W, \sin.(t), t)$
35	Šta radi funkcija $\text{append}(G_1, G_2)$ iz ControlSystems, ako su G_1, G_2 funkcije prenosa?	Formira model sa dva ulaza i dva izlaza koji se opisuje matricom funkcija prenosa na čijoj glavnoj dijagonali se nalaze G_1 i G_2 .
36	Nabrojati glavne funkcije iz ControlSystems paketa za postupno povezivanje delova modela.	Redna veza: series, paralelna veza parallel, i povratna sprega feedback.

37	Kako se vrši vremenska diskretizacija modela upotrebom ControlSystems paketa? Objasniti potrebne informacije na primeru koda.	Upotrebom funkcije c2d gde se zadaju kontinualan model i perioda odabiranja. $m = \dots$ # LTI model $T_s = 0.1$ # perioda odabiranja $md = c2d(m, T_s)$ # vremenski diskretan model
38	Šta je parametarska identifikacija?	Određivanje modela koji je poznat sa tačnošću do nepoznatih parametara.
39	Kakav je to <i>gray-box</i> model identifikacije?	Primenjena teorija odredi oblik (klasu) modela, a preko merenja se izračunaju nepoznati delovi modela (tipično nepoznati parametri). 
40	Nabrojati načine sprovođenja identifikacije.	1. off-line – sprovodi se nezavisno od rada sistema, 2. on-line – sprovodi se tokom rada sistema – neposredno nakon merenja 3. identifikacija u realnom vremenu – kao on-line ali se sprovodi nakon svake periode odabiranja.
41	Napisati definiciju identifikacije (po Zadehu).	Identifikacija je određivanje na osnovu ulaznih i izlaznih signala procesa, modela iz određene klase modela, koji je ekvivalentan procesu na kome su izvršena merenja.
42	Koja su 3 neophodna ulaza u proces identifikacije?	1) struktura modela 2) definisan kriterijum ekvivalencije (kriterijum za ocenu valjanosti modela) 3) podaci dobijeni merenjima (eksperimentalno dobijeni podaci)
43	Definisati korake is postupka identifikacije	1. Napravi se eksperiment i prikupe (izmere) ulazno/izlazni podaci sistema 2. filtriranje podaka 3. definiše se klasa modela (struktura modela) 4. izračuna konkretan model na osnovu podataka i kriterijuma optimanosti 5. ispituju se osobine modela 6. ukoliko model ne zadovoljava vraća se na korake prvo 4, pa 3, pa 2, pa 1
44	Ako je model $y(t) = q \cdot u(t)$ kako se određuje nepoznati parametar q ? 	Za više parova vrednosti ulaza u_k i izmerenog izlaza y_k , $k = 1, 2, \dots, K$ formiraju se vektori $Y = [y_1 \ y_2 \ \dots \ y_K]^T$ i $U = [u_1 \ u_2 \ \dots \ u_K]^T$, i izračuna se $q = (U^T U)^{-1} U^T Y$

45	Ako je model $y(t) = q_1 u_1(t) + q_2 u_2(t)$ kako se određuju nepoznati parametri q_1, q_2 ?	Za više parova vrednosti ulaza $u_{k,1}, u_{k,2}$ i izmerenog izlaza $y_k, k = 1, 2, \dots, K$ formiraju se $Y = [y_1 \ y_2 \ \dots \ y_K]^T$ i $U = \begin{bmatrix} u_{1,1} & u_{2,1} & \dots & u_{K,1} \\ u_{1,2} & u_{2,2} & \dots & u_{K,2} \end{bmatrix}^T$, i izračuna se $q = (U^T U)^{-1} U^T Y$
46	Kada kažemo da je procena parametara tačna?	Procena parametara je tačna kada je nepomerena i efikasna.
47	Kada kažemo da je procena parametara efikasna?	Procena parametara je efikasna kada za veliki broj merenja K važi da rasipanje procene $E\{(q - \hat{q})(q - \hat{q})^T\} = \sigma_{\hat{q}}^2$ teži nuli, tj. $\lim_{K \rightarrow \infty} \sigma_{\hat{q}}^2 \rightarrow 0$
48	Kada kažemo da je procena parametara nepomerena?	Kada je očekivana vrednost procene parametra jednaka tačnoj vrednosti $E\{\hat{q}\} = q$.
49	Kakve osobine ima beli šum?	1. Srednja vrednost 0, a standardna devijacija 1 2. Autokorelacija je 0 za sve pomeraje signala $k = 1, 2, 3, \dots$ 3. Vrednosti se generišu po normalnoj raspodeli.
50	Šta je osobina identifiabilnosti? Kada model nije identifiabilan?	Osobina identifiabilnosti određuje da li se parametri modela mogu odrediti. Model nije identifiabilan kada su funkcije osetljivosti linearno zavisne.
51	Kako modelujemo obojen šum?	Obojen šum se dobija propuštanjem belog šuma kroz filter: a) Opisan funkcijom diskretnog prenosa b) Koji kombinuje nekoliko poslednjih vrednosti.
52	Definisati ARX model i napisati šta je šta?	ARX je vremenski diskretan dinamički model:  $A(z)y(k) = B(z)u(k) + v(k)$, gde su: izlaz y , ulaz u , beli šum v , a $A(z), B(z)$ su polinomi po $z = e^{sT}$.
53	Definisati ARMAX model i napisati šta je šta?	ARMAX je vremenski diskretan dinamički model: $A(z)y(k) = B(z)u(k) + C(z)v(k)$, gde su: izlaz y , ulaz u , beli šum v , a $A(z), B(z), C(z)$ su polinomi po $z = e^{sT}$.
54	Šta je pseudoslučajan binarni signal? Gde se koristi?	To je vremenski diskretizovan signal sa vrednostima $\{a, -a\}$ koje se nasumično menjaju u svakom trenutku odabiranja. Koristi se kao ulaz u identifikaciji dinamičkih modela.

55	Kojom metodom se identifikuju parametri ARX modela, objasniti?	Metodom najmanjih kvadrata jer je izlaz linearan po nepoznatim parametrima koje množe (poznate) ranije vrednosti ulaza i izlaza. Npr. $y(k) = -a_1y(k-1) - a_2y(k-2) + b_1u(k-1) + b_2u(k-2) + v(k)$
56	Kojom metodom se identifikuju parametri ARMAX modela, ukratko objasniti?	Metodom najmanjih kvadrata koja se primenjuje dva puta: 1) napravi se adekvatan ARX model i procene njegovi parametri, 2) proceni se šum i odrede parametri ARMAX modela. U oba slučaja je izlaz modela linearan po nepoznatim parametrima koje množe (poznate) ranije vrednosti ulaza i izlaza (i procenjene vrednosti šuma).
57	Zašto je dobro poznavati kašnjenje u identifikaciji parametara ARX modela?	Zato što se smanjuje broj B parametara koji se identifikuju. Ako se kašnjenje ne modeluje, a postoji, identifikuju se B parametri iako se zna da su im vrednosti nula.
58	Kako u identifikaciji možemo proceniti red (stepene polinoma) AR(MA)X modela? 	Proces računanja parametara modela se pokreće više puta za razne kombinacije dužina polinoma A i B i posmatra se vrednost funkcije cilja J . Dobro procenjen model ima malo J uz što manje dužine polinoma.
59	Kada se u identifikaciji primenjuje rekursivna metoda najmanjih kvadrata?	Kada se parametri modela menjaju tokom rada sistema.
60	Šta je faktor zaboravljanja? Napisati kriterijum gde se upotrebljava?	Faktor zaboravljanja je parametar ρ koji se koristi u funkciji cilja za rekursivnu metodu najmanjih kvadrata kada želimo da damo manji značaj ranijim merenjima. $J_p = \frac{1}{2} \sum_{i=0}^k \rho^{k-1} (y_i - \mathbf{U}_i^T \mathbf{q})^2, \quad 0 < \rho \leq 1$
61	Kako identifikujemo <u>promenljive</u> parametre ARX modela? 	Rekursivnom metodom najmanjih kvadrata.
62	Koje nove informacije koristi rekursivna metoda najmanjih kvadrata u svakoj iteraciji?	Kako se primenjuje u identifikaciji u realnom vremenu, metoda koristi tekući izmeren izlaz sistema i tekući ulaz u sistem.
63	Koja metoda je najpogodnija za identifikaciju ARX modela u realnom vremenu? 	Rekursivna metoda najmanjih kvadrata.
64	Kako identifikujemo parametre modela gde je izlaz nelinearan po parametrima?	Iterativnim algoritmima poput Gradijentnog ili Gaus-Njutnovog algoritma.

65	Kako glasi funkcija cilja u parametarskoj identifikaciji nelinearnog modela?	$\mathcal{J}(q) = \frac{1}{2} \sum_{k=0}^{K-1} e_k^2(q)$, tj. suma po svim merenjima gde je greška e_k razlika izmerenog izlaza i izlaza modela koji je nelinearan po nepoznatim parametrima q .
66	Gde su potrebne funkcije osetljivosti u parametarskoj identifikaciji nelinearnog modela?	Funkcije osetljivosti se koriste radi provere osobine identifiabilnosti, kao i za određivanje parametara alritmima gde se koristi gradijent funkcije cilja (za njegovo računanje je potrebno odrediti i izvod izlaza modela po parametrima = funkcije osetljivosti).
67	Da li je model $y(t) = (q_1 + q_2)u(t)$ identifiabilan? Objasniti.	Nije, jer su funkcije osetljivosti linearno zavisne (jednake su). $\frac{\partial y}{\partial q_1} = \frac{\partial y}{\partial q_2} = u$ 
68	Napisati model veštačkog neurona i objasniti šta je šta?	$o = f(\sum_i w_i x_i + b)$, o izlaz, x_i ulazi, w_i i b su podesive težine, f je aktivaciona funkcija.
69	Napisati primer nelinearne aktivacione funkcije.	Npr. sigmoid: $f(z) = \frac{1}{1+e^{-z}}$
70	Šta se menja tokom obuke neuroske mreže?	Težine w i b unutar modela neurona.
71	Šta čini obučavajući skup za obučavanje sa učiteljem?	Obučavajući skup čine parovi ulaza i željenog izlaza modela.
72	Šta je epoha?	Epoha je jedna iteracija u procesu obuke neuronske mreže gde se težine doteruju na osnovu jednog prolaza kroz obučavajući skup.
73	Kakva je arhitektura neuronske mreže sa propagacijom signala unapred?	Neuronski mrežu sa propagacijom signala unapred čine slojevi neurona povezani tako da su izlazi jednog sloja ulazi u naredni sloj (i tako sve do izlaznog sloja).
74	Šta su rekurentne neuronske mreže?	Rekurentne neuronske mreže sadrže sloj neurona čiji izlaz zavisi od ulaza i od prethodnog izlaza tog sloja. Tako se realizuje memorija-stanje od čega zavisi izlaz.
75	Ako <i>fully connected</i> neuronska mreža sa propagacijom signala unapred ima 2 ulaza, skriveni sloj sa 5 neurona i 3 izlaza, koliko ima podesivih parametara u njoj?	Sloj 1 ima W matricu težina dimenzije: 5×2 Sloj 2 ima W matricu težina dimenzije: 3×5 Svaki neuron ima b težinu: $5 + 3$. Ukupno parametara: $10+15+8 = 33$
76	Definisati kriterijum optimalnosti za obuku neuronske mreže.	Kriterijum optimalnosti je suma grešaka E_p za sve elemente obučavajućeg skupa

		$J = \sum_{p=1}^P E_p$. Greška E_p je mera odstupanja izlaza mreže od željenog izlaza (tipično iskazana kao suma kvadrata po svim izlazima).
77	Šta je u osnovi Back-propagation algoritam?	BP algoritam je gradijentni algoritam koji se koristi za obuku neuronske mreže.
78	Napisati formulu gde se koristi koeficijent brzine obučavanja (<i>learning rate</i>) za „doterivanje“ težina tokom obuke neuronske mreže.	Korekcija težina tokom jedne iteracije (epohe) je $\Delta w = -\eta \frac{\partial J}{\partial w}$ gde je J funkcija cilja, a η koef. brzine obučavanja.
79	Šta se propagira unazad tokom obuke neuronske mreže BP algoritmom?	Propagira se uticaj na grešku na izlazu mreže.
80	Napisati kod za izračunavanje izlaza jednog neurona čija je aktivaciona funkcija σ . Šta treba promeniti u kodu da se računanje sprovede za ceo obučavajući skup?	U modelu jednog neurona W je vektor vrsta, a b skalar. Izlaz je skalar $o = \sigma(W \cdot x + b)$ gde je x vektor kolona ulaza, o je skalar. Kada se posmatra ceo obučavajući skup, tada je x matrica (više vektora po kolonama) i $W \cdot x + b$ je vektor vrsta. Izmena treba da omogući rad sa nizovima: $o = \sigma.(W \cdot x . + b)$
81	Šta u osnovi donosi momentum član u BP algoritam?	Kod računanja Δw kombinuju se vrednosti gradijenta funkcije cilja iz tekuće i prethodne iteracije (momentum član).
82	Da li je neuronska mreža sa propagacijom signala unapred može upotrebiti kao statički model sistema? Objasniti.	Da, jer statički model mapira ulaze na izlaze bez memorisanja prethodnih izlaza, što čini i neuronska mreža sa propagacijom signala unapred.
83	Kako se neuronska mreža sa propagacijom signala unapred može upotrebiti kao dinamički model sistema?	Tako što se model mreže proširi dodatnim ulazima na koje se dovode pored tekuće vrednosti ulaza i vrednosti ulaza i izlaza iz nekoliko ranijih trenutaka.
84	Definisati nelinearni ARX tip modela (NARX).	$y(k) = f(y(k-1), y(k-2), \dots, y(k-n), u(k-1), u(k-2), \dots, u(k-m))$ gde je: y izlaz, u ulaz, a f nelinearna funkcija.